

# SOUTENANCE DE PROJET

## Fairness en imagerie médicale

### Chest X-Ray NIH14

Alexis VO

▪ Tianqi



▪ Rakul N



LDD IM, fairness in AI

Vendredi 10 avril 2026

université  
PARIS-SACLAY

## Question de recherche

Peut-on réduire les disparités de **fairness** dans un modèle de classification de radiographies thoraciques, sans trop dégrader la **balanced accuracy** ?

- Identifier les principaux biais présents dans les **métadonnées** du dataset
- Comparer deux stratégies de mitigation :
  - **pre-processing** par reweighing
  - **post-processing** par ajustement de seuils
- Évaluer le compromis entre **équité** et **performance** pour un modèle **ResNet18**

**Idée clé** : le modèle n'utilise que l'image en entrée, mais les métadonnées restent indispensables pour **auditer** et **corriger** les biais.

## Dataset étudié

**NIH Chest X-ray 14**, avec des images compressées en **256×256**. Le projet s'appuie sur **trois sous-datasets** du groupe :  **N**  et **Vo**.

## Dataset étudié

**NIH Chest X-ray 14**, avec des images compressées en **256×256**. Le projet s'appuie sur **trois sous-datasets** du groupe :  **N**  et **Vo**.

## Comparaison des sous-datasets

| Sous-dataset                                                                      | Images | Patients | % malade |
|-----------------------------------------------------------------------------------|--------|----------|----------|
|  | 5401   | 1500     | 45.6     |
|  | 5708   | 1500     | 48.0     |
| Vo                                                                                | 5336   | 1500     | 45.3     |

## Dataset étudié

NIH Chest X-ray 14, avec des images compressées en  $256 \times 256$ . Le projet s'appuie sur trois sous-datasets du groupe :  et Vo.

## Comparaison des sous-datasets

| Sous-dataset                                                                      | Images | Patients | % malade |
|-----------------------------------------------------------------------------------|--------|----------|----------|
|  | 5401   | 1500     | 45.6     |
|  | 5708   | 1500     | 48.0     |
|  | 5336   | 1500     | 45.3     |

## Contraintes méthodologiques

- Code d'entraînement fourni
- Modèle utilisé : **ResNet18**
- Le modèle prend **uniquement l'image** en entrée
- Les métadonnées servent à :
  - auditer les biais
  - construire des corrections

## Dataset étudié

NIH Chest X-ray 14, avec des images compressées en  $256 \times 256$ . Le projet s'appuie sur trois sous-datasets du groupe :  et Vo.

## Comparaison des sous-datasets

| Sous-dataset                                                                      | Images | Patients | % malade |
|-----------------------------------------------------------------------------------|--------|----------|----------|
|  | 5401   | 1500     | 45.6     |
|                                                                                   | 5708   | 1500     | 48.0     |
| Vo                                                                                | 5336   | 1500     | 45.3     |

## Contraintes méthodologiques

- Code d'entraînement fourni
- Modèle utilisé : **ResNet18**
- Le modèle prend **uniquement l'image** en entrée
- Les métadonnées servent à :
  - auditer les biais
  - construire des corrections

## Question centrale

Jusqu'où peut-on améliorer la fairness sans trop perdre en **balanced accuracy** ?

## 1. Audit des biais

Analyse des métadonnées pour détecter les disparités selon View Position, Patient Age et Patient Gender.

## 1. Audit des biais

Analyse des métadonnées pour détecter les disparités selon View Position, Patient Age et Patient Gender.

## 2. Correction avant et après apprentissage

- **Pre-processing** : reweighing des couples groupe  $\times$  label
- **Entraînement / prédiction** : pipeline **ResNet18** fourni
- **Post-processing** : ajustement de seuils distincts pour PA et AP



## 1. Audit des biais

Analyse des métadonnées pour détecter les disparités selon View Position, Patient Age et Patient Gender.

## 2. Correction avant et après apprentissage

- **Pre-processing** : reweighing des couples groupe  $\times$  label
- **Entraînement / prédiction** : pipeline **ResNet18** fourni
- **Post-processing** : ajustement de seuils distincts pour PA et AP

## 3. Évaluation comparative

Comparaison des méthodes avec les métriques : **Balanced Accuracy**, **DIR**, **SPD**, **EOD** et **AOD**.

## 1. Audit des biais

Analyse des métadonnées pour détecter les disparités selon View Position, Patient Age et Patient Gender.

## 2. Correction avant et après apprentissage

- **Pre-processing** : reweighing des couples groupe  $\times$  label
- **Entraînement / prédiction** : pipeline **ResNet18** fourni
- **Post-processing** : ajustement de seuils distincts pour PA et AP

## 3. Évaluation comparative

Comparaison des méthodes avec les métriques : **Balanced Accuracy**, **DIR**, **SPD**, **EOD** et **AOD**.

Audit  $\rightarrow$  Reweighing  $\rightarrow$  ResNet18  $\rightarrow$  Post-processing  $\rightarrow$  Évaluation

## Constat principal

Dans les trois sous-datasets, la variable `View Position` est celle qui présente la disparité la plus forte avant modélisation.

## Constat principal

Dans les trois sous-datasets, la variable View Position est celle qui présente la disparité la plus forte avant modélisation.

## Comparaison des biais initiaux


| Sous-dataset                                                                           | DIR Genre | DIR Position | DIR Âge |
|----------------------------------------------------------------------------------------|-----------|--------------|---------|
| <br>o | 0.966     | 1.371        | 1.153   |
|                                                                                        | 1.013     | 1.327        | 1.174   |
|                                                                                        | 1.150     | 1.343        | 1.162   |

## Constat principal

Dans les trois sous-datasets, la variable View Position est celle qui présente la disparité la plus forte avant modélisation.

## Comparaison des biais initiaux

| Sous-dataset                                                                           | DIR Genre | DIR Position | DIR Âge |
|----------------------------------------------------------------------------------------|-----------|--------------|---------|
| <br>o | 0.966     | 1.371        | 1.153   |
|                                                                                        | 1.013     | 1.327        | 1.174   |
|                                                                                        | 1.150     | 1.343        | 1.162   |




Exemple illustratif sur le sous-dataset 

## Constat principal

Dans les trois sous-datasets, la variable View Position est celle qui présente la disparité la plus forte avant modélisation.

## Comparaison des biais initiaux

| Sous-dataset                                                                            | DIR Genre | DIR Position | DIR Âge |
|-----------------------------------------------------------------------------------------|-----------|--------------|---------|
| <br>Vo | 0.966     | 1.371        | 1.153   |
|                                                                                         | 1.013     | 1.327        | 1.174   |
|                                                                                         | 1.150     | 1.343        | 1.162   |



Exemple illustratif sur le sous-dataset Lu

**Lecture :** la disparité liée à View Position est la plus forte et surtout la plus **stable** sur les trois sous-datasets.

# Pourquoi View Position est le biais principal ?

## Interprétation

AP / PA correspond à une **condition technique d'acquisition**, pas à la pathologie elle-même.

Si le modèle exploite cette différence, il peut apprendre un **shortcut technique** au lieu de se concentrer sur les signes cliniques.

## Indice empirique

Avant modélisation, les cas malade sont plus fréquents en AP qu'en PA, et les métriques de fairness montrent une disparité forte sur cette variable.

Exemple représentatif :

- DIR Position élevé
- SPD Position éloigné de 0

# Pourquoi View Position est le biais principal ?

## Interprétation

AP / PA correspond à une **condition technique d'acquisition**, pas à la pathologie elle-même.

Si le modèle exploite cette différence, il peut apprendre un **shortcut technique** au lieu de se concentrer sur les signes cliniques.

## Indice empirique

Avant modélisation, les cas malade sont plus fréquents en AP qu'en PA, et les métriques de fairness montrent une disparité forte sur cette variable.

Exemple représentatif :

- DIR Position élevé
- SPD Position éloigné de 0

## Conséquence pour le projet

Nous choisissons donc View Position comme **première cible de mitigation**, avant d'examiner d'autres attributs comme l'âge.



## Principe

Le reweighing modifie les **poids d'entraînement** pour rééquilibrer les couples **groupe protégé**  $\times$  **label**.

L'idée est de :

- augmenter le poids des combinaisons sous-représentées ;
- réduire le poids des combinaisons sur-représentées ;
- corriger les déséquilibres **avant** l'apprentissage.

## Principe

Le reweighing modifie les **poids d'entraînement** pour rééquilibrer les couples **groupe protégé** × **label**.

L'idée est de :

- augmenter le poids des combinaisons sous-représentées ;
- réduire le poids des combinaisons sur-représentées ;
- corriger les déséquilibres **avant** l'apprentissage.

## Implémentation dans le notebook

Fonction centrale :

- `compute_reweighing_factor`

Poids construits :

- `W_POSITION`
- `W_AGE`
- `W_POSITION_AGE`

## Principe

Le reweighing modifie les **poids d'entraînement** pour rééquilibrer les couples **groupe protégé**  $\times$  **label**.

L'idée est de :

- augmenter le poids des combinaisons sous-représentées ;
- réduire le poids des combinaisons sur-représentées ;
- corriger les déséquilibres **avant** l'apprentissage.

## Implémentation dans le notebook

Fonction centrale :

- `compute_reweighing_factor`

Poids construits :

- `W_POSITION`
- `W_AGE`
- `W_POSITION_AGE`

## But

Tester si une correction **avant entraînement** améliore la fairness sans modifier l'architecture du modèle.

## Exemples représentatifs : Baseline vs W\_POSITION

| Sous-dataset                                                                      | Méthode    | BA    | DIR Position | SPD Position |
|-----------------------------------------------------------------------------------|------------|-------|--------------|--------------|
|  | Baseline   | 0.700 | 1.848        | 0.242        |
|                                                                                   | W_POSITION | 0.691 | 1.383        | 0.175        |
|                                                                                   | Baseline   | 0.693 | 1.916        | 0.314        |
|                                                                                   | W_POSITION | 0.684 | 1.250        | 0.123        |
| Vo                                                                                | Baseline   | 0.649 | 2.384        | 0.349        |
| Vo                                                                                | W_POSITION | 0.619 | 1.173        | 0.054        |

## Exemples représentatifs : Baseline vs W\_POSITION

| Sous-dataset                                                                      | Méthode    | BA    | DIR Position | SPD Position |
|-----------------------------------------------------------------------------------|------------|-------|--------------|--------------|
|  | Baseline   | 0.700 | 1.848        | 0.242        |
|                                                                                   | W_POSITION | 0.691 | 1.383        | 0.175        |
|                                                                                   | Baseline   | 0.693 | 1.916        | 0.314        |
|                                                                                   | W_POSITION | 0.684 | 1.250        | 0.123        |
| Vo                                                                                | Baseline   | 0.649 | 2.384        | 0.349        |
| Vo                                                                                | W_POSITION | 0.619 | 1.173        | 0.054        |

## Lecture

Le reweighing améliore déjà nettement la fairness sur View Position, avec une baisse généralement **modérée** de la balanced accuracy.

## Principe

Le post-processing agit **après l'entraînement** : on ne modifie ni le dataset, ni l'architecture du modèle, mais uniquement la **règle de décision finale**.

## Principe

Le post-processing agit **après l'entraînement** : on ne modifie ni le dataset, ni l'architecture du modèle, mais uniquement la **règle de décision finale**.

## Règle de décision

Au lieu d'utiliser un seuil unique, nous appliquons deux seuils distincts :

- un seuil pour les images PA
- un seuil pour les images AP

$$\hat{y} = 1 \quad \text{si} \quad score_{\text{malade}} \geq \begin{cases} thr_{PA} & \text{si View Position} = PA \\ thr_{AP} & \text{si View Position} = AP \end{cases}$$

## Principe

Le post-processing agit **après l'entraînement** : on ne modifie ni le dataset, ni l'architecture du modèle, mais uniquement la **règle de décision finale**.

## Règle de décision

Au lieu d'utiliser un seuil unique, nous appliquons deux seuils distincts :

- un seuil pour les images PA
- un seuil pour les images AP

$$\hat{y} = 1 \quad \text{si} \quad score_{\text{malade}} \geq \begin{cases} thr_{PA} & \text{si View Position} = PA \\ thr_{AP} & \text{si View Position} = AP \end{cases}$$

## Recherche des seuils

Nous testons plusieurs couples de seuils sur une grille simple :

$$\{0.3, 0.4, 0.5, 0.6, 0.7\}$$


afin d'identifier une correction efficace sur View Position.




## Objectif

Améliorer les métriques de fairness (**DIR**, **SPD**) tout en limitant la perte de **balanced accuracy**.

## DIR Position avant / après post-processing



## DIR Position avant / après post-processing



## Lecture

Ce graphique compare deux situations :

- le modèle **baseline** ;
- le modèle déjà corrigé par **W\_POSITION**.

Dans les deux cas, le post-processing rapproche fortement le **DIR Position** de 1, ce qui confirme que l'ajustement de seuils reste efficace, y compris après reweighing.

## Pre-processing

- agit **avant** l'entraînement
- améliore déjà la fairness
- baisse généralement **modérée** de BA
- correction plus structurelle

## Pre-processing

- agit **avant** l'entraînement
- améliore déjà la fairness
- baisse généralement **modérée** de BA
- correction plus structurelle

## Post-processing

- agit **après** l'entraînement
- correction la plus forte sur View Position
- baisse de BA parfois plus marquée selon le dataset
- méthode simple et directe

## Pre-processing

- agit **avant** l'entraînement
- améliore déjà la fairness
- baisse généralement **modérée** de BA
- correction plus structurelle

## Post-processing

- agit **après** l'entraînement
- correction la plus forte sur View Position
- baisse de BA parfois plus marquée selon le dataset
- méthode simple et directe

## Message principal

La fairness doit être pensée comme un problème de **pipeline complet** : audit des biais, correction avant ou après apprentissage, puis arbitrage entre **équité** et **performance**.

## Pre-processing

- agit **avant** l'entraînement
- améliore déjà la fairness
- baisse généralement **modérée** de BA
- correction plus structurelle

## Post-processing

- agit **après** l'entraînement
- correction la plus forte sur View Position
- baisse de BA parfois plus marquée selon le dataset
- méthode simple et directe

## Message principal

La fairness doit être pensée comme un problème de **pipeline complet** : audit des biais, correction avant ou après apprentissage, puis arbitrage entre **équité** et **performance**.

## Limites et perspectives

- nombre d'entraînements limité ;
- seuils choisis sur validation ;
- analyse surtout centrée sur View Position ;
- perspectives : groupes intersectionnels et seuils appris automatiquement.